

Tugas Implementasi Generative AI

Nama : Putri Torsia Aura Prameswary
NIM : 2546000083
Mata Kuliah / Kelas : Pembelajaran Mesin / B

1. Dataset yang Digunakan

a. **Dataset Vision:** Fashion-MNIST

Fashion-MNIST adalah dataset gambar grayscale berukuran 28x28 piksel yang terdiri dari 60.000 data training dan 10.000 data testing. Dataset ini memiliki 10 kelas pakaian yaitu T-shirt, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, dan Ankle Boot. Dataset diakses langsung melalui torchvision.datasets dan dinormalisasi menggunakan transforms.ToTensor() sehingga nilai piksel berada di rentang 0 sampai 1.

b. **Dataset Text:** Cerita Pendek Budi dan Kitty

Dataset teks dibuat sendiri berupa cerita pendek berbahasa Indonesia tentang seorang anak bernama Budi dan kucingnya bernama Kitty. Teks terdiri dari 21 kalimat dengan total sekitar 1.100 karakter. Pemrosesan dilakukan secara character-level sehingga setiap karakter unik menjadi satu token. Setelah preprocessing didapatkan ukuran vocabulary sebesar 45 karakter unik.

2. Konsep Generative AI

Generative AI adalah jenis model kecerdasan buatan yang tidak hanya mengenali pola dari data, tetapi juga mampu menciptakan data baru yang belum pernah ada sebelumnya. Kunci dari kemampuan ini terletak pada proses pembelajaran distribusi data. Setelah distribusi dipahami, model dapat mengambil sampel baru dari distribusi tersebut untuk menghasilkan output yang terlihat nyata dan masuk akal. Generative AI berbeda secara fundamental dari model klasifikasi. Model klasifikasi bersifat diskriminatif, artinya ia belajar memisahkan kelas dan menjawab pertanyaan "data ini masuk kategori mana?". Sebaliknya, model generatif belajar distribusi data itu sendiri dan menjawab pertanyaan "data seperti apa yang mungkin muncul dari distribusi ini?". Beberapa konsep penting dalam Generative AI antara lain adalah latent space, yaitu ruang representasi tersembunyi berukuran kecil yang menyimpan fitur inti dari data setelah dikompresi oleh encoder. Sampling adalah proses mengambil nilai secara acak dari distribusi probabilitas yang sudah dipelajari model. Noise vector adalah vektor acak dari distribusi normal standar $N(0,1)$ yang menjadi titik awal proses generasi. Prompt adalah instruksi atau konteks yang diberikan ke model untuk mengarahkan outputnya dari distribusi $p(x)$ menjadi distribusi bersyarat $p(x|c)$.

3. Algoritma yang Digunakan

Dalam tugas ini diimplementasikan empat model generatif dari dua domain yang berbeda.

a. Domain Vision:

- Model pertama adalah Variational Autoencoder (VAE). VAE bekerja dengan cara mengompresi gambar input ke distribusi probabilitas di

ruang laten melalui encoder, kemudian melakukan sampling dari distribusi tersebut untuk mendapatkan vektor z , lalu merekonstruksi gambar menggunakan decoder. Karena proses generasinya berbasis sampling dari distribusi, VAE mampu menghasilkan gambar baru yang tidak pernah dilihat sebelumnya.

- Model kedua adalah Autoencoder Standar (AE). AE bekerja mirip dengan VAE namun tanpa komponen probabilistik. Encoder mengompresi input ke satu titik tetap di ruang laten, bukan ke distribusi. Akibatnya AE tidak bisa digunakan untuk menghasilkan gambar baru dari noise acak, tetapi kualitas rekonstruksinya cenderung lebih tajam.

b. Domain Text:

- Model ketiga adalah LSTM Text Generator. LSTM menggunakan mekanisme long short-term memory dengan tiga gate (input, forget, output) dan cell state terpisah untuk memproses urutan karakter secara autoregressive. Model ini memprediksi karakter berikutnya berdasarkan urutan karakter sebelumnya.
- Model keempat adalah GRU Text Generator. GRU memiliki arsitektur yang lebih sederhana dari LSTM dengan dua gate (reset dan update) tanpa cell state terpisah. Arsitektur yang lebih ringan membuat GRU lebih cepat dalam training meski menghasilkan performa yang hampir setara dengan LSTM pada dataset kecil.

4. Rumus Utama Algoritma

- Variational Autoencoder (VAE)

Proses encoding menghasilkan dua parameter distribusi yaitu mean (μ) dan log variance ($\log_var$). Sampling dilakukan menggunakan reparameterization trick:

$$z = \mu + \sigma \cdot \varepsilon, \text{ dengan } \varepsilon \sim N(0, I)$$

$$\mathcal{L} = \mathcal{L}_{\text{rekonstruksi}} + \mathcal{L}_{\text{KL}}$$

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}(q_{\phi}(z|x) \parallel p(z)) = -0.5 \cdot \sum (1 + \log_var - \mu^2 - \exp(\log_var))$$

- **Autoencoder Standar (AE)**

Proses encoding langsung menghasilkan vektor z tanpa komponen probabilistik:

$$z = f\theta(x)$$

$$\hat{x} = g\phi(z)$$

$$\mathcal{L} = \|x - \hat{x}\|^2$$

- **Text Generation (LSTM dan GRU)**

Kedua model text menggunakan prinsip autoregressive:

$$p(x_1, x_2, \dots, x_T) = \text{hasil kali dari } t=1 \text{ sampai } T \text{ dari } p(x_t | x_1, \dots, x_{t-1})$$

Loss dihitung menggunakan Cross Entropy:

$$\mathcal{L} = -\sum (y_{-i} \cdot \log(\hat{y}_{-i}))$$

5. Hubungan Rumus dengan Kode PyTorch

Konsep	Rumus	Bagian Kode PyTorch
Encoder	$z = f\theta(x)$	<code>self.encoder(x)</code>
Decoder	$\hat{x} = g\phi(z)$	<code>self.decoder(z)</code>
Reconstruction Loss	$\mathcal{L} = \ x - \hat{x}\ ^2$	<code>nn.MSELoss()</code>
KL Loss	$D_{KL}(q\phi(z x) \parallel p(z))$	<code>(x)</code>
Reparameterization	$z = \mu + \sigma \cdot \epsilon$	<code>mu + eps * torch.exp(0.5 * logvar)</code>
Generator GAN	$G(z)$	<code>fake = generator(z)</code>
Discriminator GAN	$D(x)$	<code>real_pred = discriminator(real)</code>
Attention	$\text{softmax}(QK^T / \sqrt{d_k}) \cdot V$	<code>nn.MultiheadAttention()</code>
Cross Entropy	$-\sum(y \log \hat{y})$	<code>nn.CrossEntropyLoss()</code>

6. Implementasi Generative AI untuk Vision

- **Arsitektur VAE**

Encoder VAE terdiri dari dua layer konvolusi dengan filter 32 dan 64, stride 2, diikuti dua fully connected layer untuk menghasilkan μ dan $\log_var$ masing-masing berukuran 20 dimensi ($\text{latent_dim} = 20$). Decoder menerima vektor z berukuran 20 lalu merekonstruksi gambar melalui dua layer transposed convolution. Fungsi aktivasi yang digunakan adalah ReLU pada encoder dan Sigmoid pada output decoder.

Total parameter VAE: ditampilkan pada output Section 5 notebook.


```
Parameter VAE : 228,905
Parameter AE  : 166,165
```

- **Arsitektur AE**

Autoencoder standar memiliki arsitektur encoder yang identik dengan VAE namun outputnya langsung menghasilkan vektor z berukuran 20 tanpa pemisahan μ dan $\log_var$. Loss yang digunakan hanya MSELoss tanpa komponen KL.

- **Proses Training Vision**

Kedua model dilatih selama 10 epoch menggunakan optimizer Adam dengan learning rate 0.001 dan batch size 128.



7. Implementasi Generative AI untuk Text

- **Arsitektur LSTM dan GRU**

Kedua model text memiliki konfigurasi yang hampir identik yaitu `embedding_dim = 128`, `hidden_dim = 256`, `num_layers = 2`, dan `dropout = 0.2`. Perbedaan utama ada pada recurrent layer yang digunakan, yaitu `nn.LSTM` untuk model pertama dan `nn.GRU` untuk model kedua. Pada LSTM, `init_hidden` mengembalikan tuple (h, c) karena ada dua state, sedangkan pada GRU hanya mengembalikan satu tensor h . Pemrosesan teks dilakukan secara character-level. Setiap karakter dikonversi ke indeks menggunakan kamus `char2idx`. Input sequence berukuran 100 karakter dan target sequence adalah input yang digeser satu posisi ke depan.


Parameter LSTM: 931,610
Parameter GRU : 701,210

- **Proses Training Text**


Kedua model dilatih selama 30 epoch menggunakan optimizer Adam dengan learning rate 0.001 dan batch size 16. Loss dihitung menggunakan `nn.CrossEntropyLoss`.

8. Hasil Gambar yang Dihasilkan


- **VAE Generated Images:** VAE dapat menghasilkan gambar baru dengan cara melakukan sampling vektor z dari distribusi normal standar $N(0, I)$ lalu melewatkannya ke decoder. Gambar yang dihasilkan terlihat menyerupai pakaian dari Fashion-MNIST namun memiliki sedikit efek blur. Hal ini merupakan karakteristik umum VAE karena proses regularisasi KL Divergence mendorong latent space agar lebih smooth dan kontinu sehingga decoder menghasilkan output berupa nilai rata-rata dari berbagai kemungkinan.



- AE Reconstruction: AE tidak bisa menghasilkan gambar dari noise acak karena latent space-nya tidak terstruktur sebagai distribusi. Sebagai gantinya, AE ditampilkan kemampuan rekonstruksinya dari gambar test. Hasil rekonstruksi AE terlihat lebih tajam dan detail dibanding VAE karena tidak ada regularisasi distribusi yang mempengaruhi proses rekonstruksi.



- Perbandingan Original vs VAE vs AE: Dari visualisasi perbandingan terlihat bahwa rekonstruksi AE lebih mendekati gambar original secara piksel, sedangkan rekonstruksi VAE sedikit lebih buram meski masih dapat dikenali.



9. Hasil Teks yang Dihasilkan

Generasi teks dilakukan menggunakan prompt "budi dan" dengan panjang output 100 karakter dan tiga nilai temperature yang berbeda.

Perbandingan Generasi (Prompt: 'budi dan')

--- Temperature: 0.5 ---
 LSTM: budi dan kitty menjelajahi sawah hijau, bermain di bawah sinar matahari.
 kitty sering mengejar kupu-kupu, me
 GRU : budi dan kitty menjelajahi sawah hijau, bermain di bawah sinar matahari.
 kitty sering mengejar kupu-kupu, me

--- Temperature: 1.0 ---
 LSTM: budi dan kitty menjelajahi sawah hijau, bermain di bawah sinar matahari.
 kitty sering mengejar kupu-kupu, me
 GRU : budi dan kitty menjelajahi sawah hijau, bermain di bawah sinar matahari.
 kitty sering mengejar kupu-kupu, me

--- Temperature: 1.5 ---
 LSTM: budi dan kitty menjelajahi sawah hijau, bermain di bawah sinar matahari.
 kit tiba-tiba menghilang.
 budi menc
 GRU : budi dan kitty menjelajahi sawah hijau, bermain di bawah sinar matahari.
 kitty sering mengejar kupu-kupu, me

Dari hasil generasi terlihat beberapa pola. Pada temperature 0.5 teks yang dihasilkan cenderung lebih repetitif karena model selalu memilih token dengan probabilitas tertinggi. Pada temperature 1.0 teks lebih bervariasi namun masih cukup koheren. Pada

temperature 1.5 teks lebih beragam dan kreatif namun beberapa kali menghasilkan kombinasi karakter yang kurang masuk akal.

10. Perbandingan Model



Tabel 1: Vision (VAE vs Autoencoder)

Aspek	VAE	Autoencoder
Kualitas Gambar	Sedikit blur karena regularisasi KL	Lebih tajam karena rekonstruksi langsung
Stabilitas Training	Stabil, loss turun perlahan	Konvergen lebih cepat
Jenis Loss	Reconstruction Loss + KL Divergence	Hanya Reconstruction Loss (MSE)
Kemudahan Implementasi	Sedang, perlu reparameterization trick dan dua fungsi loss	Mudah, hanya satu fungsi loss MSE
Generate Data Baru?	Ya, sampling dari $N(0,1)$ di latent space	Tidak, hanya merekonstruksi input
Loss Akhir	243.66 per sampel	8.00 per sampel
Waktu Training	86.44 detik	79.94 detik

Tabel 2: Text (LSTM vs GRU)

Aspek	LSTM	GRU
Kualitas Kalimat	Sangat koheren pada 30 epoch	Sangat koheren pada 30 epoch
Koherensi Teks	Cukup koheren, mampu mempertahankan alur cerita	Cukup koheren, hasil serupa dengan LSTM
Repetisi Kata	Kadang berulang pada temperature rendah	Kadang berulang, frekuensi hampir sama
Kesalahan Grammar	Ada kesalahan pada kata sambung dan akhiran karena character-level	Ada kesalahan serupa, tidak lebih baik dari LSTM
Pengaruh Panjang Prompt	Prompt lebih panjang menghasilkan teks lebih terfokus	Sama, prompt panjang memberi konteks lebih baik

Loss Akhir	0.0514	0.0516
Waktu Training	24.77 detik	24.15 detik



11. Analisis Hasil

- Analisis Model Vision

VAE berhasil mempelajari distribusi data Fashion-MNIST dan mampu menghasilkan gambar baru melalui sampling dari ruang laten. Gambar yang dihasilkan menyerupai pakaian dalam dataset namun memiliki sedikit kekaburan. Kekaburan ini bukan kegagalan melainkan konsekuensi dari regularisasi KL Divergence yang mendorong latent space agar smooth. Semakin smooth latent space, semakin mudah melakukan interpolasi antar titik tetapi semakin buram pula gambar yang dihasilkan. Autoencoder menghasilkan rekonstruksi yang lebih tajam karena tidak ada regularisasi distribusi. Namun kelemahan mendasarnya adalah ia tidak bisa digunakan untuk menghasilkan data baru karena latent space-nya tidak terstruktur sebagai distribusi yang bisa disampling secara acak.

- Analisis Model Text

LSTM dan GRU menunjukkan performa yang sangat mirip pada dataset kecil ini. Loss akhir keduanya nyaris identik di angka 0.05 dan waktu training hanya berbeda sekitar 0.62 detik. Ini menunjukkan bahwa untuk dataset berukuran kecil seperti cerita Budi dan Kitty, kompleksitas tambahan dari LSTM tidak memberikan keunggulan signifikan. Kualitas teks yang dihasilkan sangat dipengaruhi oleh nilai temperature. Temperature rendah menghasilkan teks yang lebih prediktif dan cenderung mengulang frasa yang sering muncul di data training. Temperature tinggi menghasilkan variasi lebih besar namun berisiko menghasilkan kombinasi karakter yang tidak bermakna.

- Analisis Loss vs Kualitas Generasi

Loss kecil tidak selalu menjamin hasil generasi yang bagus. Pada model text, loss 0.05 setelah 30 epoch menunjukkan bahwa model sudah sangat baik dalam memprediksi karakter berikutnya pada data training. Namun pada temperature rendah model tetap menghasilkan pengulangan karena terlalu "percaya diri" dengan pola yang paling sering muncul. Kualitas generasi harus

dievaluasi bukan hanya dari loss tetapi juga dari koherensi, variasi, dan relevansi output secara keseluruhan.

12. Kesimpulan

Tugas ini berhasil mengimplementasikan dan membandingkan empat model generatif pada dua domain yang berbeda yaitu Vision dan Text menggunakan PyTorch di Google Colab. Pada domain Vision, VAE terbukti lebih unggul untuk keperluan generasi gambar baru karena memiliki latent space yang terstruktur sebagai distribusi probabilitas. AE lebih unggul untuk keperluan rekonstruksi gambar karena menghasilkan output yang lebih tajam tanpa gangguan regularisasi. Pilihan model bergantung pada tujuan penggunaan. Pada domain Text, LSTM dan GRU menunjukkan performa yang hampir setara pada dataset kecil. GRU sedikit lebih efisien dalam waktu training karena arsitekturnya yang lebih sederhana. Untuk dataset yang lebih besar dan urutan yang lebih panjang, LSTM kemungkinan akan menunjukkan keunggulan yang lebih signifikan karena kemampuannya menangani dependensi jangka panjang yang lebih baik. Secara umum, terdapat trade-off yang jelas antara kompleksitas model dan kualitas output. Model yang lebih kompleks seperti VAE dibanding AE memerlukan penanganan loss yang lebih rumit namun memberikan kemampuan generatif yang lebih kuat. Pada teks, kompleksitas LSTM tidak selalu berbuah hasil yang lebih baik jika ukuran dataset tidak memadai. Loss kecil adalah syarat perlu tetapi bukan syarat cukup untuk menghasilkan output generasi yang berkualitas baik.

13. Referensi dan Sumber Kode

- Link Repository GitHub Pengumpulan:
<https://github.com/putriprameswary/generative-ai-pytorch>
- PyTorch Official Documentation. <https://pytorch.org/docs>
- Torchvision Datasets: Fashion-MNIST.
<https://pytorch.org/vision/stable/datasets.html>
- Kingma, D. P. and Welling, M. (2013). Auto-Encoding Variational Bayes. arXiv:1312.6114
- Goodfellow, I. et al. (2014). Generative Adversarial Networks. arXiv:1406.2661
- Hochreiter, S. and Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation.
- Cho, K. et al. (2014). Learning Phrase Representations using RNN Encoder-Decoder. arXiv:1406.1078
- Vaswani, A. et al. (2017). Attention Is All You Need. arXiv:1706.03762
- Xiao, H. et al. (2017). Fashion-MNIST: a Novel Image Dataset. arXiv:1708.07747